Úloha 1: Dvourozměrná náhodná veličina

Pavel Kratochvíle, Michal Malík

KMA/MSM 2026/2027 – Mnohorozměrné statistické metody | 24. 10. 2026

1 Cíl a popis programu

- Na zvoleném dvourozměrném rozdělení provést celý postup od **teorie** po **simulaci**.
- Spočítat konstantu, marginály, momenty a kovarianční matici, vygenerovat data a porovnat odhady s teorií.
- Ukázat, jak přesnost odhadů závisí na rozsahu výběru n.

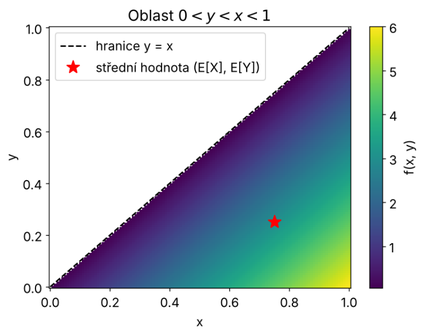
2 Zvolené rozdělení

$$f(x,y) = c\,(x-y), \qquad D = \{0 < y < x < 1\}$$

$$\text{Z normování } \iint_D f \,\mathrm{d}y\,\mathrm{d}x = 1 \text{ plyne}$$

$$c\int_0^1\int_0^x (x-y)\,\mathrm{d}y\,\mathrm{d}x = \frac{c}{6} = 1 \quad \Rightarrow \quad \boxed{c = 6}$$



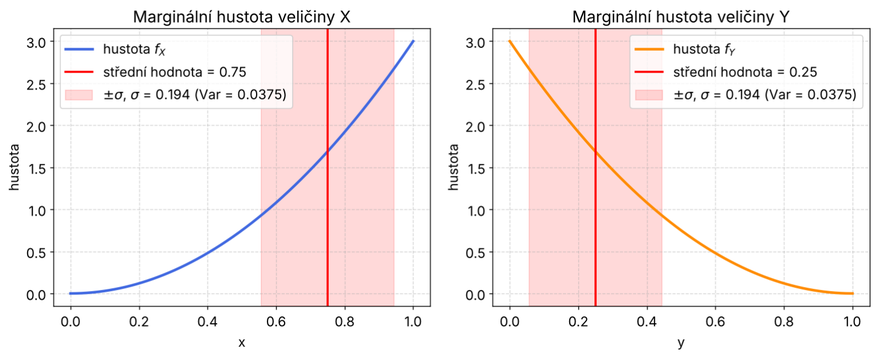


3 Marginální rozdělení

	hustota	distribuční funkce
X	$f_X(x) = 3x^2$	$F_X(x) = x^3$
Y	$f_Y(y) = 3(1-y)^2$	$F_Y(y) = 1-(1-y)^3$

- $f_X(x) = \int_0^x 6(x-y)\,\mathrm{d}y, \quad f_Y(y) = \int_y^1 6(x-y)\,\mathrm{d}x$
- X a Y jsou **závislé**: oblast není obdélník, $f \neq f_X f_Y$.

4 Teoretické charakteristiky



$$\mathbb{E}[X] = \tfrac{3}{4}, \quad \mathbb{E}[Y] = \tfrac{1}{4}, \quad \mathrm{Var}(X) = \mathrm{Var}(Y) = \tfrac{3}{80}$$
$$\mathbb{E}[XY] = \tfrac{1}{5}, \quad \mathrm{Cov}(X,Y) = \tfrac{1}{80}, \quad \rho = \tfrac{1}{3}$$
$$\boldsymbol{\Sigma} = \frac{1}{80}\begin{pmatrix} 3 & 1 \\ 1 & 3 \end{pmatrix}$$

- Střední hodnota = těžiště rozdělení, rozptyl = šířka kolem něj.
- Kladná kovariance: omezení $y < x$ svazuje obě veličiny.
- $\rho = \frac{1}{3}$ je korelační koeficient (kovariance bez jednotek, $\rho \in [-1,1]$): jde o **mírnou kladnou lineární závislost**.

5 Generování dat – rejection sampling

1. Kandidát (x,y) rovnoměrně z $(0,1)^2$.
2. Náhodné $u \sim \mathrm{U}(0,M)$, $M = 6 \geq \max f$.
3. Přijmi, pokud $u \leq f(x,y)$; jinak zahoď.

Pravděpodobnost přijetí $= \dfrac{1}{M \cdot 1} = \dfrac{1}{6}$ (v průměru 6 kandidátů na jeden vzorek).

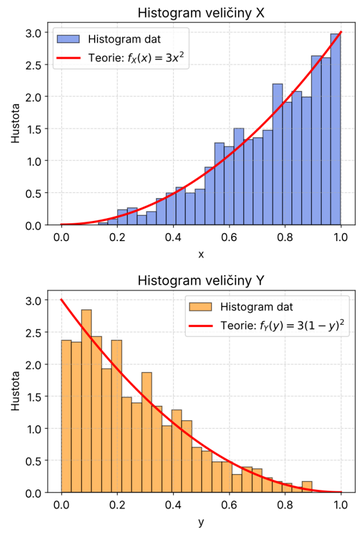
6 Odhady z dat ($n = 1000$)

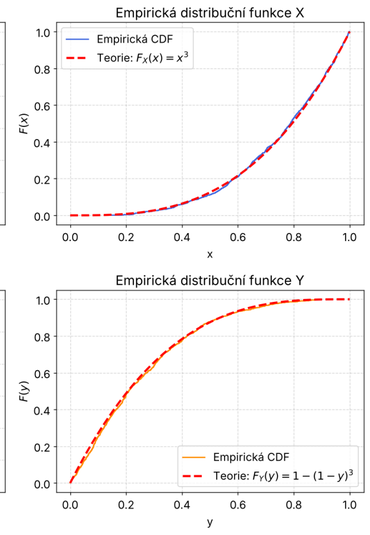
	teorie	odhad
$\mathbb{E}[X]$	$3/4 = 0.7500$	0.7499
$\mathbb{E}[Y]$	$1/4 = 0.2500$	0.2577
$\mathrm{Var}(X)$	$3/80 = 0.0375$	0.0355
$\mathrm{Var}(Y)$	$3/80 = 0.0375$	0.0382
$\mathrm{Cov}(X,Y)$	$1/80 = 0.0125$	0.0122

95% intervalové odhady středních hodnot ($\bar{x} \pm 1{,}96\, s/\sqrt{n}$):

	interval	pokrývá teorii
$\mathbb{E}[X]$	(0.7382; 0.7616)	ano
$\mathbb{E}[Y]$	(0.2456; 0.2698)	ano

7 Porovnání s teorií

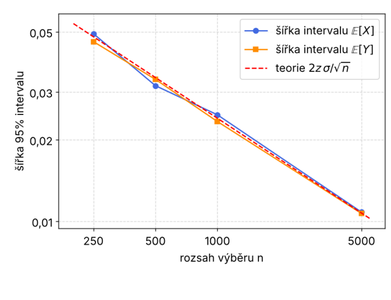




- Histogramy kopírují tvar teorie (f_X roste k $x = 1$, f_Y klesá od $y = 0$): generátor i marginály jsou správně.
- Zubatost sloupců je náhodná (počet bodů v binu kolísá), největší tam, kde je hustota malá.
- ECDF téměř splývá s F_X, F_Y: $D_n(X) = 0{,}021$, $D_n(Y) = 0{,}035$, pod kritickou hodnotou KS testu na 5 % ($\approx 0{,}043$) – bez systematické odchylky od teorie.

8 Závislost na rozsahu výběru

n	$\bar{x}$	šířka	$\bar{y}$	šířka	$D_n(X)$	$D_n(Y)$
250	0.7334	0.0493	0.2216	0.0461	0.060	0.085
500	0.7573	0.0317	0.2523	0.0334	0.030	0.037
1000	0.7461	0.0247	0.2520	0.0234	0.022	0.027
5000	0.7490	0.0108	0.2481	0.0107	0.008	0.012



- Šířka intervalu klesá jako $1/\sqrt{n}$: čtyřnásobek dat $\Rightarrow$ poloviční šířka (250 $\to$ 1000: 0,049 $\to$ 0,025 u $\mathbb{E}[X]$).
- D_n také klesá (u X z 0,060 na 0,008), ECDF se přimyká k F.
- Chyba odhadu kolísá (pro každé n jen jeden výběr), spolehlivější je šířka intervalu.

9 Technologie, závěr, využití AI

Technologie: Python 3 – `random`, `math`, `numpy`, `matplotlib`.
Závěr:

- Odhady ($n = 1000$) se od teorie liší nejvýše o 0,008 a oba 95% intervaly teoretickou střední hodnotu pokrývají.
- Generátor i ručně spočtené charakteristiky jsou konzistentní.
- Větší n = užší intervaly, s klesajícím přínosem (10× přesněji = 100× více dat).

Využití AI: AI (Claude) sloužila k vysvětlení teorie, kontrole postupu a ladění a úpravě struktury kódu; výpočty a řešení vypracoval autor.